

Aplicaciones con LLMs

Inteligencia Artificial e Ingeniería del Conocimiento

Constantino Antonio García Martínez

Universidad San Pablo Ceu

APIs Vs. Modelos Locales

LLM APIs vs. Modelos Locales

APIs Comerciales

Ventajas:

- Sin requisitos de hardware
- Modelos de última generación
- Escalabilidad instantánea
- Mantenimiento por el proveedor
- Actualizaciones frecuentes

Desventajas:

- Coste por uso
- Dependencia de conexión
- Datos enviados a terceros
- Límites de rate-limit
- Vendor lock-in

Modelos Locales

Ventajas:

- Control total de datos
- Sin costes recurrentes
- Privacidad garantizada
- Sin límites de uso
- Funciona offline

Desventajas:

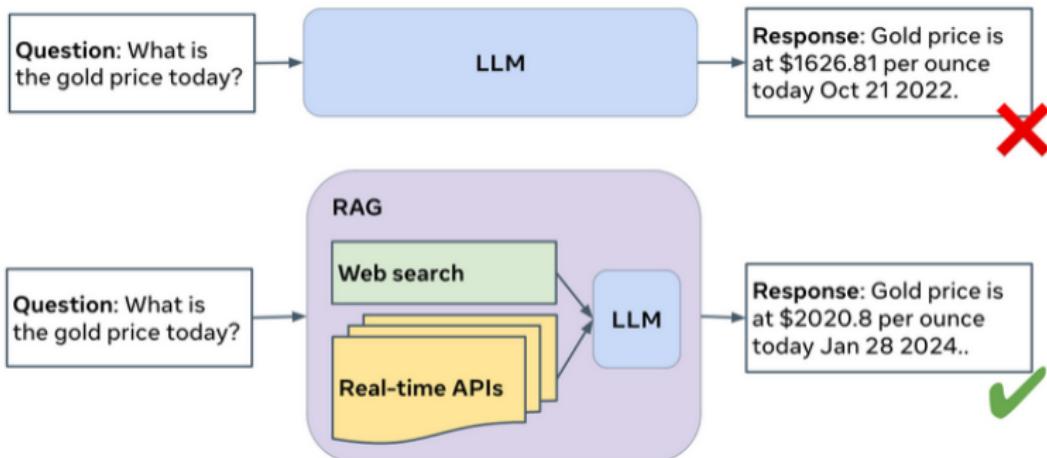
- Requiere hardware potente
- Mantenimiento propio
- Modelos menos capaces
- Complejidad de deployment
- Actualizaciones manuales

Acceso a LLMs por API: Demo

Example: `7-api_demo_mistral.py`

Caso de Estudio: RAG

RAG: Retrieval-Augmented Generation



1

¹ Fuente: <https://kddcup24.github.io/index.html>

RAG: Retrieval-Augmented Generation

Example: [8-RAG.ipynb](#)

Vector Databases

Vector Stores: Gestión Eficiente de Embeddings

¿Por qué necesitamos vector stores especializados?

- **Escala:** Una base documental puede generar millones de embeddings
 - 10,000 documentos × 100 chunks/doc = 1M embeddings
 - Vector de 768 dimensiones × 4 bytes = 3KB por embedding
 - Total: ~3GB solo en embeddings
- **Búsqueda eficiente:** Calcular similitud con 1M vectores es costoso
 - Búsqueda lineal: $O(n \cdot d)$ donde d es la dimensionalidad
 - Vector stores usan índices aproximados (ANN: Approximate Nearest Neighbor): $O(\log n)$
 - Algoritmos:
 - Hierarchical Navigable Small World graphs (HNSW)
 - Inverted File Index (IVF)
 - Locality-Sensitive Hashing (LSH)
- **Persistencia y actualización:** Añadir/eliminar documentos dinámicamente
- **Filtrado y metadatos:** Búsqueda híbrida (semántica + metadatos)

Algunos de los Vector Databases más usados son: Pinecone, Chroma, FAISS, Weaviate, Milvus, Qdrant, etc.